

PARTIC :

- Prediction 1 :

Vocabulary của corpus 30K documents sẽ có khoảng 60.000 unique terms.

Vì : +> Mỗi documents chỉ dùng 1 phần nhỏ từ vựng
+> Corpus web có nhiều tên riêng, lỗi chính tả, ...

- Prediction 2 :

TF-IDF matrix sẽ là ~~dens~~ sparse

Ước lượng tỷ lệ zero entries khoảng

- Prediction 3 :

Các document đứng đầu không nhất thiết luôn là các document gần nghĩa nhất

Lý do : TF-IDF ưu tiên các từ xuất hiện giống nhau. Hai câu cùng nghĩa nhưng dùng từ khác nhau có thể nhận similarity thấp