

PART D:

$$N = 30.000$$

$$V = 193.540$$

$$nnz = 4.985.822$$

$$\text{Sparsity} = 99.914129\%$$

Ma trận TF-IDF gồm 30.000 documents và 193.540 term trong vocabulary. Mỗi document chỉ chứa một phần nhỏ số term này nên phần lớn các chiều có giá trị 0. Vì vậy, ma trận có độ thưa cao: 99.914129%.

Gemma

Term phổ biến như "the" xuất hiện trong 27,893/30000 document nên có DF cao ~~nhỏ~~ và IDF thấp. Ngược lại các term hiếm có IDF cao nhất là 10.615839. Tuy nhiên, IDF cao không đảm bảo TF-IDF cao ở mọi document vì TF-IDF còn phụ thuộc vào tần suất term trong document cụ thể. VD, "bbq" có TF-IDF 0.461808 trong D00000

PART F:

1) Lowercasing giảm vocabulary từ 240,444 xuống 193,540 terms, chênh 46,904 terms. Khi giữ chữ hoa / thường các dạng case $\neq$ nhau có thể bị xem là các term riêng

2) Stopword removal giảm số units trung bình từ 351,338800 xuống 190,132600 mỗi document và giảm vocabulary 314 terms. Mean P@5 của A, B, C đều là 0.0 nên chưa có bằng chứng rằng stopwords removal cải thiện search

3) Punctuation normalization thay ký tự đặc biệt bằng khoảng trắng. Nó có thể làm mất cấu trúc của URL, mã định danh, tên hàm, ngày tháng, tên ghép.

4) Pipeline B thua nhất $A = 0.999141$; $B = 0.999367$; $C = 0.967260$. Sparsity cao hơn nghĩa là nhiều giá trị 0 hơn, không đồng nghĩa search tốt hơn

5) Theo mean P@5, cả A, B, C đều bằng 0.0 nên chưa xác định được pipeline tốt nhất. MRR của A/B là 0.000179, cao hơn C là 0.000065

6) Chưa thể kết luận vocabulary nhỏ hơn giúp search tốt hơn. A có 193,540; B có 193,226; C có 50,000 terms

Gemma

PART H:

Mean P@5 và Recall@5 của cả 3 pipeline đều bằng 0.0. Điều này nghĩa là không có document relevant nào xuất hiện trong 5. A và B có MRR 0,000179, cao hơn C với 0,000065. Relevant document vẫn xuất hiện trong ranking nhưng ở vị trí thấp.

PART I:

⊗ Poor query 1:

- Query: wild garlic pesto shrimp pasta
- relevant document: D01288
- top 5:
 - D01287: 0,738128
 - D01429: 0,304559
 - D05296: 0,294381
 - D29310: 0,234804
 - D11271: 0,230072
- D01288 không nằm trong top 5, chỉ xuất hiện ở rank 1893
- P@5 và Recall@5 đều bằng 0.0
- ~~D01287 đứng đầu.~~

⊗ Poor query 2:

- Query: image overlay manipulation
- Relevant document: D27936
- top 5:
 - D27935: 0.377595
 - D19908: 0,198690
 - D17794: 0,188561
 - D15682: 0,182652
 - D12982: 0.176446

CRABIT

1

D27936 ko nằm trong top 5, chỉ xuất hiện ở rank 28.012

⊗ Failure case

- Query: image overlap manipulation.
- Relevant document: D27936
- Relevant rank: 28012
- Top result: D27935

D27936 liên quan nhg bị xếp rất thấp. D27935 xếp cao. Case này cho thấy TF-IDF ưu tiên lexical overlap và có thể bỏ lỡ tài liệu liên quan khi cách diễn đạt khác nhau.

PART I :

16. Reflection

- Kết quả bất ngờ nhất là TF-IDF matrix có sparsity 99,914129% với 30.000 document và 193.540 terms. Điều này cho thấy phần lớn chiều của mỗi vector sẽ gần 0

- Evidence mạnh nhất đến từ Part F và Part H. Pipeline B có sparsity cao nhất.

- Failure case quan trọng nhất là "image overlay manipulation".

- Nếu xây lại search engine, em sẽ thử query expansion để hỗ trợ

- AI hỗ trợ code, kiểm tra queries. Em tự đánh giá relevance, prediction và reflection.